

Построение аддитивной регрессионной модели по мотивам теоремы Колмогорова

Карташов Игорь Олегович
Группа J3212

5 июня 2026 г.

Аннотация

В данной работе я решаю задачу восстановления неизвестной регрессионной зависимости $y = f(x_1, \dots, x_p) + \varepsilon$ по обучающей выборке. Основной исследуемой моделью является аддитивная модель, в которой многомерная функция приближается суммой одномерных компонент. Каждая компонента аппроксимируется конечным набором базисных функций, благодаря чему задача оценки параметров сводится к линейной регрессии в расширенном пространстве признаков. В вычислительном эксперименте модель сравнивается с линейной регрессией и полной полиномиальной моделью с взаимодействиями. Отдельно исследуется влияние числа базисных функций на качество аппроксимации, а также поведение аддитивной модели на данных с неаддитивной зависимостью.

1 Постановка задачи

Пусть имеется выборка наблюдений

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n, \quad x_i = (x_{i1}, \dots, x_{ip}) \in [0, 1]^p,$$

где x_i — вектор признаков, y_i — наблюдаемое значение целевой переменной. Предполагается, что наблюдения описываются моделью

$$y_i = f(x_{i1}, \dots, x_{ip}) + \varepsilon_i,$$

где f — неизвестная регрессионная функция, а ε_i — случайный шум.

Цель работы состоит в том, чтобы построить вычислительно реализуемую модель для восстановления функции f , сравнить её с альтернативными регрессионными моделями и исследовать условия, при которых аддитивное представление является эффективным. Особое внимание уделяется не только численному качеству прогноза, но и интерпретируемости полученных компонент.

В работе решаются следующие задачи:

- 1) построить синтетическую обучающую и тестовую выборки для аддитивной регрессионной зависимости;
- 2) реализовать аддитивную модель через базисное разложение одномерных компонент;

- 3) сформировать блочную матрицу признаков Z и оценить параметры методом наименьших квадратов и ridge-регрессией;
- 4) центрирование компонент для устранения неоднозначности представления;
- 5) сравнить аддитивную модель с линейной регрессией и полной полиномиальной моделью с взаимодействиями;
- 6) исследовать влияние числа базисных функций на ошибку обучения и тестирования;
- 7) отдельный эксперимент на неаддитивных данных и показать ограничение аддитивной модели.

2 Теоретическая основа

2.1 Мотивация через теорему Колмогорова

Теорема Колмогорова о представлении непрерывной функции утверждает, что непрерывная функция многих переменных на единичном кубе может быть представлена через суперпозиции непрерывных функций одного аргумента и операцию сложения. В общем виде такое представление записывается как

$$f(x_1, \dots, x_p) = \sum_{k=1}^{2p+1} h_k \left(\sum_{i=1}^p \varphi_{ik}(x_i) \right),$$

где h_k и φ_{ik} являются одномерными функциями.

В данной работе не строится полное суперпозиционное представление Колмогорова. Вместо этого используется более простая и вычислительно устойчивая модель — аддитивная регрессия. Она сохраняет основную идею построения многомерной зависимости из одномерных функций, но не использует внешние функции h_k и вложенные суперпозиции.

2.2 Аддитивная модель

Аддитивная модель имеет вид

$$\hat{f}(x) = \beta_0 + \sum_{j=1}^p g_j(x_j),$$

где β_0 — свободный член, а g_j — одномерная функция, описывающая вклад j -го признака.

Если положить

$$g_j(x_j) = \beta_j x_j,$$

то аддитивная модель переходит в обычную линейную регрессию

$$\hat{f}_{\text{lin}}(x) = \beta_0 + \sum_{j=1}^p \beta_j x_j.$$

Следовательно, линейная регрессия является частным случаем аддитивной модели. Главное отличие состоит в том, что в аддитивной модели функции g_j могут быть нелинейными, что позволяет описывать более сложные зависимости при сохранении интерпретируемости отдельных вкладов признаков.

2.3 Базисное разложение компонент

Поскольку функции g_j заранее неизвестны, каждая из них аппроксимируется конечным набором базисных функций:

$$g_j(t) = \sum_{m=1}^M a_{jm} \psi_m(t),$$

где $\psi_m(t)$ — выбранные базисные функции, a_{jm} — оцениваемые коэффициенты, M — число базисных функций на один признак.

В вычислительном эксперименте использовался полиномиальный базис

$$\psi_1(t) = t, \quad \psi_2(t) = t^2, \quad \dots \quad \psi_M(t) = t^M.$$

Тогда модель принимает вид

$$\hat{f}(x) = \beta_0 + \sum_{j=1}^p \sum_{m=1}^M a_{jm} x_j^m.$$

Несмотря на нелинейность по исходным признакам, данная модель является линейной по оцениваемым параметрам β_0 и a_{jm} .

2.4 Матрица признаков

Для каждого объекта $x_i = (x_{i1}, \dots, x_{ip})$ строится расширенный вектор признаков

$$z_i = (1, \psi_1(x_{i1}), \dots, \psi_M(x_{i1}), \dots, \psi_1(x_{ip}), \dots, \psi_M(x_{ip})).$$

Если объединить все строки z_i , получаем матрицу признаков

$$Z \in \mathbb{R}^{n \times (1+pM)}.$$

Тогда прогнозы модели записываются в матричном виде:

$$\hat{y} = Z\theta,$$

где

$$\theta = (\beta_0, a_{11}, \dots, a_{1M}, \dots, a_{p1}, \dots, a_{pM})^T.$$

2.5 Оценивание параметров

Параметры модели оцениваются минимизацией квадратичного функционала

$$Q(\theta) = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \sum_{m=1}^M a_{jm} \psi_m(x_{ij}) \right)^2.$$

В матричном виде:

$$Q(\theta) = \|y - Z\theta\|_2^2.$$

Для метода наименьших квадратов используется оценка

$$\hat{\theta} = (Z^T Z)^{-1} Z^T y,$$

если матрица $Z^T Z$ обратима. Для повышения устойчивости также рассматривается ridge-регрессия:

$$Q_\lambda(\theta) = \|y - Z\theta\|_2^2 + \lambda \|\theta\|_2^2,$$

где $\lambda \geq 0$ — параметр регуляризации.

2.6 Центрирование компонент

Аддитивное представление не является единственным: константу можно переносить между свободным членом и отдельными компонентами g_j . Для устранения этой неоднозначности вводится условие центрирования

$$\sum_{i=1}^n g_j(x_{ij}) = 0, \quad j = 1, \dots, p.$$

После обучения для каждой компоненты вычисляется среднее значение на обучающей выборке:

$$\bar{g}_j = \frac{1}{n} \sum_{i=1}^n g_j(x_{ij}).$$

Затем компонента заменяется на

$$g_j^{\text{new}}(t) = g_j(t) - \bar{g}_j,$$

а свободный член корректируется следующим образом:

$$\beta_0^{\text{new}} = \beta_0 + \sum_{j=1}^p \bar{g}_j.$$

Такая операция не меняет итоговые прогнозы модели, но делает отдельные функции g_j более интерпретируемыми.

2.7 Метрики качества

Для сравнения моделей использовались следующие метрики:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

$$\text{RMSE} = \sqrt{\text{MSE}},$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

Меньшие значения MSE и RMSE соответствуют меньшей ошибке прогноза, а значение R^2 , близкое к единице, означает высокую объясняющую способность модели.

3 Описание вычислительного эксперимента

3.1 Синтетические аддитивные данные

На первом этапе рассматривалась синтетическая зависимость, которая действительно имеет аддитивную структуру:

$$y_i = \sin(2\pi x_{i1}) + 0.5(x_{i2} - 0.5)^2 + \exp(-3x_{i3}) + \varepsilon_i,$$

где

$$x_{ij} \sim U[0, 1], \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2).$$

Таким образом, истинная функция имеет вид

$$f(x_1, x_2, x_3) = g_1(x_1) + g_2(x_2) + g_3(x_3),$$

где

$$g_1(t) = \sin(2\pi t), \quad g_2(t) = 0.5(t - 0.5)^2, \quad g_3(t) = \exp(-3t).$$

В эксперименте использовалось 1500 наблюдений. Обучающая выборка содержала 1125 объектов, тестовая выборка — 375 объектов. Признаки генерировались непосредственно на интервале $[0, 1]$, поэтому дополнительная нормализация не требовалась.




Рис. 1: Истинные одномерные компоненты аддитивной функции.

3.2 Сравнимые модели

В работе сравнивались четыре модели:

- 1) линейная регрессия;
- 2) аддитивная модель, обученная методом наименьших квадратов;
- 3) аддитивная модель с ridge-регуляризацией;
- 4) полная полиномиальная модель с взаимодействиями.

Для основной аддитивной модели использовалось $M = 7$ базисных функций на каждый признак. При $p = 3$ число параметров равно

$$1 + pM = 1 + 3 \cdot 7 = 22.$$

Для полной полиномиальной модели степени 5 число параметров составило 56.

4 Результаты на аддитивных данных

4.1 Качество моделей

Результаты сравнения моделей на аддитивных данных представлены в таблице 1.

Таблица 1: Качество моделей на синтетических аддитивных данных

Модель	Test MSE	Test RMSE	Test R^2	Число параметров
Линейная регрессия	0.215939	0.464693	0.637974	2
Аддитивная модель, МНК, $M = 7$	0.010823	0.104031	0.981856	22
Аддитивная модель, Ridge, $M = 7$	0.011024	0.104997	0.981517	22
Полиномиальная модель, Ridge, степень 5	0.013018	0.114099	0.978174	56

Результаты показывают, что линейная регрессия заметно уступает аддитивной модели. Причина в том, что исходная зависимость содержит нелинейные компоненты (синусоидальную, квадратичную и экспоненциальную), которые линейная модель не может корректно описать. В результате её качество на тестовой выборке оказалось существенно ниже ($MSE = 0.215939$, $R^2 = 0.637974$). Аддитивная модель при $M=7$ показала лучший результат: $MSE = 0.010823$, $RMSE = 0.104031$ и $R^2 = 0.981856$. Это говорит о том, что она практически полностью восстановила исходную зависимость, несмотря на наличие шума. Полиномиальная модель с взаимодействиями также продемонстрировала высокую точность, однако немного уступила аддитивной модели. При этом она использовала 56 параметров против 22 у аддитивной модели. Таким образом, для аддитивных данных аддитивная модель оказалась не только точнее, но и значительно проще.




Рис. 2: Сравнение тестовых ошибок моделей на аддитивных данных.

4.2 Центрирование и восстановление компонент

После обучения аддитивной модели были восстановлены оценки компонент

$$\hat{g}_j(t) = \sum_{m=1}^M \hat{a}_{jm} t^m.$$

Для обеспечения однозначной интерпретации было выполнено центрирование компонент. Исходный свободный член до центрирования составил

$$\beta_0 = 1.033763.$$

Средние значения компонент на обучающей выборке были равны

$$\bar{g}_1 = 0.094488, \quad \bar{g}_2 = -0.079514, \quad \bar{g}_3 = -0.667954.$$

После корректировки свободный член стал равен

$$\beta_0^{\text{new}} = 0.380782.$$




Рис. 3: Сравнение истинных и восстановленных одномерных компонент аддитивной модели.

Графики восстановленных компонент позволяют интерпретировать вклад каждого признака отдельно. Компонента g_1 отражает периодический вклад первого признака, g_2 — слабую квадратичную зависимость второго признака, а g_3 — убывающий экспоненциальный вклад третьего признака.

4.3 График истинных и предсказанных значений




Рис. 4: Истинные и предсказанные значения для аддитивной модели на тестовой выборке.

Если модель хорошо восстанавливает зависимость, точки на графике y против $\hat{y}$ должны располагаться вблизи диагонали. Для аддитивной модели на аддитивных данных наблюдается именно такая картина, что согласуется с высоким значением R^2 на тестовой выборке.

5 Влияние числа базисных функций

Число базисных функций M определяет сложность аддитивной модели. При малом M модель может оказаться слишком грубой и не восстановить нелинейные компоненты. При слишком большом M возрастает риск переобучения и численной неустойчивости.

В таблице 2 приведены результаты для различных значений M .

Таблица 2: Влияние числа базисных функций на качество аддитивной ridge-модели

M	Число параметров	Train MSE	Test MSE	Train R^2	Test R^2
1	4	0.205242	0.215939	0.663554	0.637975
2	7	0.193621	0.200119	0.682604	0.664497
3	10	0.014344	0.014310	0.976486	0.976009
5	16	0.012664	0.012774	0.979241	0.978584
7	22	0.010130	0.011024	0.983395	0.981517
10	31	0.010157	0.011400	0.983350	0.980888
12	37	0.010050	0.011224	0.983525	0.981182
15	46	0.010023	0.011139	0.983570	0.981326

Наиболее заметное улучшение качества происходит при переходе от $M = 2$ к $M = 3$: тестовая ошибка снижается с 0.200119 до 0.014310. Это объясняется тем, что модель получает достаточную гибкость для аппроксимации нелинейных компонент. Лучшее значение по тестовой ошибке было получено при $M = 7$:

$$\text{MSE}_{\text{test}} = 0.011024, \quad R^2_{\text{test}} = 0.981517.$$

Дальнейшее увеличение M не приводит к существенному улучшению качества. Следовательно, для рассматриваемой задачи разумный диапазон сложности находится около $M = 7$ –15, однако $M = 7$ является более предпочтительным вариантом из-за меньшего числа параметров.




Рис. 5: Зависимость ошибки обучения и тестирования от числа базисных функций M .

6 Эксперимент на неаддитивных данных

Для проверки ограничений аддитивной модели был проведён дополнительный эксперимент на зависимости с взаимодействием признаков:

$$y_i = \sin(2\pi(x_{i1} + x_{i2})) + 0.5x_{i3} + \varepsilon_i.$$

Эта функция не является аддитивной в смысле представления

$$f(x_1, x_2, x_3) = g_1(x_1) + g_2(x_2) + g_3(x_3),$$

поскольку переменные x_1 и x_2 входят совместно внутрь синуса. Поэтому ожидается, что модель с взаимодействиями должна иметь преимущество перед чисто аддитивной моделью.

6.1 Качество моделей на неаддитивных данных

Таблица 3: Качество моделей на синтетических неаддитивных данных

Модель	Test MSE	Test RMSE	Test R^2	Число параметров
Линейная регрессия	0.516059	0.718372	0.083553	
Аддитивная модель, Ridge, $M = 10$	0.520233	0.721272	0.076140	3
Полиномиальная модель, Ridge, степень 7	0.068074	0.260910	0.879110	12

На неаддитивных данных аддитивная модель не смогла существенно улучшить качество по сравнению с линейной регрессией. Её тестовая ошибка составила 0.520233, а $R^2 = 0.076140$. Это связано с тем, что модель пытается представить совместное влияние x_1 и x_2 как сумму отдельных функций $g_1(x_1) + g_2(x_2)$, хотя истинная зависимость содержит взаимодействие внутри выражения $\sin(2\pi(x_1 + x_2))$.

Полная полиномиальная модель с взаимодействиями показала значительно лучшее качество: $\text{MSE} = 0.068074$, $R^2 = 0.879110$. Этот результат подтверждает основное ограничение аддитивной модели: она хорошо работает для зависимостей, которые действительно близки к сумме одномерных вкладов, но плохо описывает сильные взаимодействия между признаками.




Рис. 6: Сравнение тестовых ошибок моделей на неаддитивных данных.




Рис. 7: Истинные и предсказанные значения аддитивной модели на неаддитивных данных.




Рис. 8: Истинные и предсказанные значения полной полиномиальной модели на неаддитивных данных.

7 Сравнение сложности моделей

Важным аспектом является не только качество, но и число параметров. Сводное сравнение сложности моделей приведено в таблице 4.

Таблица 4: Сравнение числа параметров моделей

Эксперимент	Модель	Число параметров
Аддитивные данные	Линейная регрессия	4
Аддитивные данные	Аддитивная модель, Ridge, $M = 7$	22
Аддитивные данные	Полиномиальная модель, степень 5	56
Неаддитивные данные	Линейная регрессия	4
Неаддитивные данные	Аддитивная модель, Ridge, $M = 10$	31
Неаддитивные данные	Полиномиальная модель, степень 7	120

На аддитивных данных модель с 22 параметрами оказалась точнее полной полиномиальной модели с 56 параметрами. Это показывает, что если структура данных соответствует предположению аддитивности, то использование более общей модели не обязательно даёт выигрыш. Напротив, чрезмерно богатая модель может быть менее интерпретируемой и требовать большего числа параметров.

На неаддитивных данных ситуация меняется: полиномиальная модель с взаимодействиями существенно превосходит аддитивную модель, но использует 120 параметров. Следовательно, выбор модели зависит от структуры зависимости: аддитивная модель эффективна при слабых взаимодействиях, а при выраженных взаимодействиях требуется более общий класс моделей.

8 Обсуждение результатов

Проведённые эксперименты показали, что аддитивная модель занимает промежуточное положение между линейной регрессией и полной нелинейной моделью. Она позволяет учитывать нелинейные зависимости, сохраняя при этом относительно простую структуру и интерпретируемость.

На аддитивных данных модель показала наилучшее качество и успешно восстановила отдельные компоненты зависимости. Однако на данных с выраженными взаимодействиями между признаками её возможностей оказалось недостаточно. В таких случаях модели с взаимодействиями обеспечивают более точный прогноз за счёт большей гибкости.

Также было установлено, что число базисных функций (M) определяет сложность модели. При малых значениях (M) качество оказывается недостаточным, а после достижения определённого уровня гибкости дальнейшее увеличение (M) почти не влияет на результат. В рассматриваемом эксперименте наилучшее качество было достигнуто при ($M=7$).

9 Выводы

В ходе работы была построена и исследована аддитивная регрессионная модель по мотивам теоремы Колмогорова. Основные результаты можно сформулировать следующим образом.

- 1) Была реализована аддитивная регрессионная модель на основе базисного разложения компонент, а задача оценивания параметров сведена к линейной регрессии.
- 2) На аддитивных данных модель показала высокое качество и практически полностью восстановила исходную зависимость.
- 3) Линейная регрессия заметно уступила аддитивной модели, поскольку не способна корректно описывать нелинейные зависимости.
- 4) Полиномиальная модель также обеспечила хорошее качество, однако потребовала большего числа параметров и не дала преимуществ на аддитивных данных.
- 5) Анализ восстановленных компонент показал, что аддитивная модель позволяет интерпретировать вклад каждого признака отдельно.
- 6) Исследование влияния числа базисных функций показало, что оптимальное качество достигается при $M = 7$, а дальнейшее усложнение модели практически не улучшает результат.
- 7) На данных с взаимодействиями между признаками аддитивная модель показала низкое качество, тогда как полиномиальная модель с взаимодействиями существенно превзошла её.
- 8) Полученные результаты показывают, что аддитивные модели хорошо подходят для зависимостей без сильных взаимодействий между признаками, сочетая высокую точность, простоту и интерпретируемость.

10 Репозиторий и воспроизводимость

Код вычислительного эксперимента представлен в виде Jupyter Notebook. Ссылка на репозиторий с кодом:

<https://github.com/IGK-arch/Construction-of-an-additive-model-based-on-Kolmogorov-s-tl>

11 Политика использования ИИ

Инструменты искусственного интеллекта использовались как вспомогательное средство для структурирования отчёта, проверки формулировок и организации вычислительного эксперимента. Численные результаты, графики и выводы основаны на выполненном автором коде и проверены в ноутбуке. Заимствованные формулировки не выдаются за самостоятельные теоретические результаты; основная часть работы представляет собой индивидуальный вычислительный эксперимент.

Список литературы

- [1] Методические материалы курса. Кейс 7: построение аддитивной модели по мотивам теоремы Колмогорова.
- [2] Взаимодействие с ИИ рамках чата с ChatGPT: <https://chatgpt.com/share/6a256602-e24c-83ed-90b2-7c67b5539b9a>